

## 1. まえがき

今日の教育現場において、大量に蓄積された教育データに対して機械学習の手法を活用し、学習者のスキル状態や設問の難易度などの情報を抽出し、効果的な教育を促進させる試みであるEducational Data Miningが注目されている[1].

Educational Data Miningの手法の一つであるKnowledge Tracingとは、学習者のスキル状態を隠れ変数、設問に関する解答結果(正答・誤答)を観測値とする隠れマルコフモデル(Hidden Markov Model: HMM)で表現される手法であり、学習履歴から学習者の潜在能力を推定して学習者の未知の設問への正答予測を行う。近年、このKnowledge Tracingにディープラーニングの手法を組み込むモデルが普及しており、比較的高い精度で正答予測を行うことが可能となった[2]。その反面、これらのモデルでは教育心理面での説明可能性に乏しく、そのために十分な性能が発揮できていないことがある。

そこで本研究では、ディープラーニングの手法を用いたKnowledge Tracingに対して、説明可能性の高いモデルの一つである項目反応理論に忘却の概念を取り入れたモデルを組み込み、精度の向上と説明可能性の関連を目標としたモデルを提案する。

## 2. 関連研究手法

### 2.1. 項目反応理論

直接観測することの出来ない潜在的能力を、複数の項目を用いて間接的に推定することを目的とした理論が項目反応理論(Item Response Theory: IRT)である。

項目反応理論では項目の形式に合わせた様々なモデルが考案されているが、中でも代表的なモデルとして、項目への反応を2種類に分類可能なテスト(正答・誤答)を対象とした1母数ロジスティックモデル(Raschモデル)が挙げられる。Raschモデルでは、設問に正答する確率 $P$ を式(1)で定義される。

$$P(\theta)_{ij} = \frac{1}{1 + \exp(-1.7(\theta_i - \beta_j))}. \quad (1)$$

式(1)において、添字 $i$ は回答者を、 $j$ は項目を表している。また、回答者ごとの変数である $\theta_i$ は被験者母数と呼ばれ、回答者の潜在能力の高さを表すためのものであり、項目ごとの変数である $\beta_j$ は難易度母数と呼ばれ、各項目の難しさを表している。

これらの変数は学習データから推定する必要があり、様々な推定方法が考案されているが、本研

究では汎用性の高いベイズ推定を用いて推定することとする。

### 2.2. Bi-GRU

DNN(Deep Neural Network)の手法の一つであり、時系列データに対して、過去から未来の1方向だけでなく未来から過去の方を追加した2方向に対応するモデルとしてBi-GRUが存在する。

時系列データを取り扱うDNNをRNN(Recurrent Neural Network)と呼ぶ。学習者の潜在能力も時間経過とともに推移していくことから、時系列データとして扱うことが可能となる。このRNNでは、長期の時間依存性を考慮したLSTM(Long Short-Term Memory)や、LSTMのパラメータ数を減らし、計算時間を抑えつつLSTMと同等かそれ以上の予測精度を持つGRU(Gated Recurrent Unit)が考案されてきた。このGRUを双方向(bi directional)に対応させたものがBi-GRUである。

このBi-GRUを用いたKnowledge Tracingの手法が、他のKnowledge Tracingの手法と比較してより高い精度を実現していることが、先行研究によって明らかとなった[3]。

## 3. 提案手法

### 3.1. モデル概要

本研究では、先行研究で提案されたBi-GRUを用いたKnowledge Tracingの手法に対して、項目反応理論に忘却の概念を取り入れたモデルを組み込んで、学習者の潜在能力推定に対する予測精度の向上を目的とした手法を提案する。本研究で提案する手法を図1に示す。

本研究のモデルの入力は、設問で使用されたスキル $q$ と、その設問を解答した結果 $r$ 、そして忘却の概念を取り入れた項目反応理論より推定された被験者母数 $\theta$ の3種類である。出力は、予測する時点の解答結果 $r$ であり、それぞれの添え字は時間を表している。 $q$ と $r$ の入力で記載されている添え字 $L$ は、一回の学習で $L$ 時点前の結果までを入力とすることを示している。 $L$ の値が小さいほど精度は高くなるが、計算時間が長く、過学習になりやすい傾向にある。

### 3.2. 忘却モデルの概要

通常、学習において、前回学習してからの経過時間が長いほど学習した内容を忘却し、学習者の潜在能力は衰える傾向にある。そこで本研究では、学習者の潜在能力を示す被験者母数 $\theta_i$ をエビングハウスの忘却曲線[4]を用いることによって、経過時間ごとに小さくなるように調整を行った。本研究で用いたエビングハウスの忘却曲線の数式を式(2)に示す。

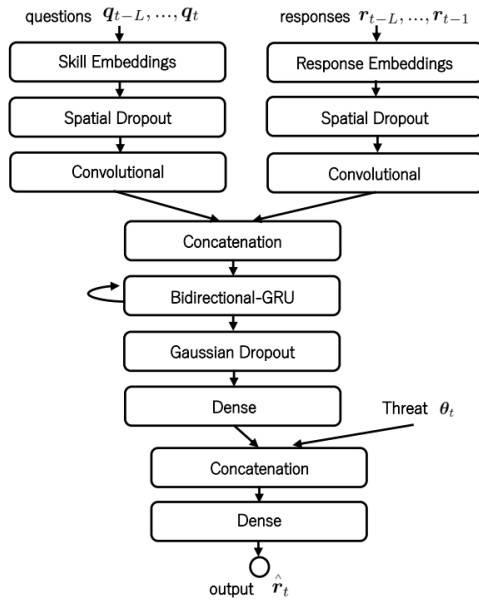


図1 本研究のモデル

$$f = 100 \times \frac{1.84}{(\log_{10} t)^{1.25} + 1.84}. \quad (2)$$

変数 $t$ は経過時間を表し、出力 $f$ は節約率を表している。節約率とは一度覚えた内容を再び習得するまでに必要な時間をどれだけ節約できたかを表す割合であり、節約率が高いほど、学習内容の覚え直しが簡単であると言える。本研究では式(2)より求められた節約率にパラメータをかけ合わせた値を、被験者母数から引くことによって忘却を表現している。

## 4. 実験

### 4.1. 実験方法

本研究で提案した手法と、先行研究で提案されたBi-GRUを用いたKnowledge Tracingの手法を同様のデータセットを用いて予測精度を比較した。評価指標にはAUC(Area Under Curve)を用いた。

### 4.2. データセット

本研究では、人工データを生成して実験を行った。人工データでは、学習者IDと設問ID、解答結果(正解を1、不正解を0で示す)、そして、学習者が解答した時間の4項目を作成した。

### 4.3. 実験結果・考察

先行研究で提案されたモデルと本研究で提案したモデルの推定精度について、訓練データを実行した際の結果を図2、テストデータを実行した際の結果を図3に示す。図2と図3はそれぞれエポック数を5とし、点線は先行研究で提案されたモデル、実線は本研究で提案したモデルを示しており、各エポックごとのAUC推移を折れ線グラフで示している。

全体的に本モデルの方が先行モデルよりも高いAUC値を出力しており、テストデータの最終的な

AUC値は、先行モデルで0.5931、本モデルで0.6076であった。また、各エポックごとのAUCの推移を見ると本研究で提案したモデルの方が学習速度が速いことがわかる。




図2 訓練データのAUC




図3 テストデータのAUC

## 5. まとめ

本研究では、予測精度の向上と教育心理面での説明可能性の両立を目的として、Bi-GRUを用いたKnowledge Tracingと忘却の概念を取り入れた項目反応理論を組み合わせた手法を提案した。今後は実践データに対して精度の向上を目指し、忘却だけでなく様々な要因を考慮したモデルを考案していきたい。

## 謝辞

本研究は、JSPS科研費19H01728の助成を受けたものです。

## 参考文献

- [1] 柿崎透真,大枝真一,“Knowledge Tracing とIRT を組み合わせた学生モデリング手法による学習者の潜在状態推定”,情報処理学会 第84回全国大会, 2022.
- [2] C. Piech, J. Bassen, J. Huang, S. Ganguli, M. Sahami, L. Guibas, and J. Sohl-Dickstein, “Deep knowledge tracing,” Advances in neural information processing systems, 28:505–513, 2015.
- [3] M. Delianidi, K. Diamantaras, G. Chrysogonidis, and V. Nikiforidis, “Student performance prediction using dynamic neural models,” in Fourteenth International Conference on Educational Data Mining (EDM 2021), pp. 46–54, 2021.
- [4] Ebbinghaus. H, “Über das gedächtnis: untersuchungen zur experimentellen psychologie,” Duncker & Humblot, 1895.